

基于动态时空编排的 LLM 推理调度优化及其在金融科技中的应用研究

摘要

随着大语言模型 LLM 在智能客服、投研辅助、风险控制、知识问答、自动报告生成等各类应用场景中的普及，模型推理服务的资源成本与响应时延逐渐成为决定业务可用性的核心因素。论文《Bullet: Boosting GPU Utilization for LLM Serving via Dynamic Spatial-Temporal Orchestration》聚焦于大模型在线服务中的一个关键瓶颈：GPU 利用率低与吞吐一时延矛盾并存。论文作者指出，LLM 推理包含两个计算特性差异显著的阶段：计算密集型的 prefill 阶段与内存带宽受限的 decode 阶段。现有系统要么偏向吞吐、牺牲延迟，要么通过 chunked prefill 改善延迟，但又导致吞吐受损和硬件闲置。为此，作者提出 Bullet 系统，凭借动态时空协同编排机制，通过并发执行 prefill 与 decode、动态分配 GPU 中的 SM 资源、结合 SLO 感知调度与 SM-scaling roofline 性能模型，实现高 GPU 利用率与低时延之间的更优平衡。论文显示，Bullet 在真实工作负载中实现了平均 $1.26\times$ 、最高 $1.55\times$ 的吞吐提升，同时持续满足延迟目标。本文将系统总结该论文的核心思想，并进一步讨论其在金融行业，尤其是智能投顾、机构知识助手、合规审查、量化研究平台、智能客服和实时风控等场景中的应用价值。

关键词：大语言模型 LLM；Bullet 系统；GPU 资源调度；时空编排；金融科技

一 引言

在人工智能技术深度赋能各行各业背景下，大语言模型已经走向大规模线上服务，成为企业数字化转型的核心工具。在线 LLM 服务区别于离线模型训练，要求系统具备高并发、低时延、高稳定性、低成本四大特征。然而，LLM 推理服务的高昂成本与不可预测的延迟，依然是阻碍其大规模商业化的两大障碍。GPU 作为主流算力平台，其利用率往往受限于 LLM 推理过程中的结构性矛盾。。

论文精准地指出了这一痛点，LLM 推理流程固定划分为处理输入提示的预填充 Prefill 阶段和生成输出 Token 的解码 Decode 阶段。预填充阶段属于计算密集型任务，而解码阶段对内存带宽要求极高，二者硬件诉求存在根本性差异：吞吐导向架构会牺牲响应时延，广泛使用的分块预填充技术虽优化延迟，却造成 GPU 算力闲置、整体吞吐量下降，叠加波量化、注意力计算低效等问题，硬件资源浪费现象十分突出。

而金融行业又是大模型落地的重点领域，同时对推理服务提出严苛要求。

金融业务具备时效性要求高、访问流量波动剧烈、算力成本昂贵、合规性强等特点，传统推理调度方案难以兼顾金融业务的多重诉求，算力瓶颈逐渐成为金融 AI 深化应用的阻碍。

在此背景下，论文提出的 Bullet 动态时空编排推理系统提供了全新的优化思路。本文首先梳理论文研究背景与现有技术缺陷，解读 Bullet 的架构设计、核心算法与实验效果；其次结合金融细分业务场景，分析该技术的适配性与应用价值；最后总结技术落地优势、现存挑战与未来发展方向，探讨大模型推理优化技术在金融领域的发展前景。

二 论文核心问题：prefill 与 decode 的结构性矛盾

2.1 推理两阶段的资源特性差异

LLM 单次推理分为预填充、解码两个强关联阶段，硬件需求完全对立。

- Prefill 阶段：并行处理输入上下文，属于计算密集型。
- Decode 阶段：逐 token 生成输出，属于内存带宽受限型。

这两个阶段对 GPU 资源的需求方向不同：一个偏计算，一个偏访存。这种差异导致系统很难始终保持高利用率。

2.2 两类主流方案的局限性

论文指出，现有方法通常有两类，但接存在显著局限性。

1. 吞吐导向系统

这类系统优先做 prefill，以提高整体吞吐，但会导致 decode 排队变长，延迟恶化。文档中明确提到，这类方式会让 prefill “垄断 GPU 资源”，从而损害响应延迟。

2. Chunked Prefill

工业界广泛采用的方法是把长输入切成块，与 decode 混合批处理。这样做可以一定程度改善首 token 时延，但论文中指出它有明显缺陷：

- chunk 过小，会造成 GPU 利用不足。
- chunk 过大，又会抵消时延改善。

其本质上仍然在吞吐与延迟之间做妥协。论文进一步指出，造成低效的根本原因有两点——第一，prefill 存在 wave quantization 和 attention 效率问题。第二，hybrid batching 过度偏向延迟控制，浪费了计算与带宽资源。换言之，现有方法并没有真正解决“两个阶段资源特性不同”这一结构性矛盾。

盾，只是做了折中。

三 Bullet 的核心思想：动态时空协同编排

根据论文摘要和方法片段，Bullet 提出了一套新的系统机制，核心是让 prefill 与 decode 更细粒度地并发执行，并动态调整 GPU 中 SM (streaming multiprocessor) 的分配比例。

3.1 整体架构设计

1. 并发执行引擎

Bullet 提出了一个 concurrent execution engine，支持异步 CPU 控制流与 GPU 执行。该引擎能够在控制面和数据面协调依赖关系，并以“微秒级开销”进行实时调度。这意味着系统可以更频繁地重划分 SM 资源，而不会引入过大的额外成本。

2. SM-scaling Roofline Model

论文指出，已有通用争用建模方法需要大量 profiling，而 LLM 特定方法又过于经验化。为此，Bullet 构建了一个 SM-scaling roofline model，把计算、内存和网络带宽等资源行为与 SM 预算联系起来，以较少采样实现较高建模精度。

这是关键的一点，因为如果没有可靠的性能模型，系统就无法知道“此刻给 prefill 多少 SM、给 decode 多少 SM”才最优。

3. SLO-aware Scheduler

论文中明确提到，Bullet 设计了 SLO-aware scheduler，根据系统运行状态与请求速率波动，动态地、分层地决定 SM 分区。它关注两个关键指标：

- TTFT (time-to-first-token, 首 token 时间)
- TPOT (time-per-output-token, 单 token 输出时间)

这表明 Bullet 不是单纯追求吞吐，而是尝试在用户体验与资源效率之间找到动态平衡。

3.2 实验性能结果

论文基于 Llama3.1、Qwen 等主流大模型，使用 A100、H100 等商用 GPU，结合对话、代码、长文本三类真实负载开展对比实验，对标 vLLM、SGLang、Nano 等主流推理框架，实验结果如下：

1. 吞吐量：平均提升 1.26 倍，最高达 1.55 倍，高并发场景优势显著。

2. 延迟表现：首令牌延迟大幅优化，单令牌延迟仅有小幅增长，全程符合预设延迟约束。
3. 硬件利用率：GPU 平均活跃 SM 占比达到 86.2%，张量核心、内存带宽利用率同步提升。
4. 运行开销：元数据交互、性能预测、资源重配均为微秒/亚毫秒级，不影响线上业务。

实验充分证明，Bullet 实现了低时延与高吞吐兼顾，突破了传统方案的固有瓶颈。

四 论文整体贡献

根据论文摘要和实验结论，Bullet 相较现有方法有如下贡献：

1. 揭示现有 prefill-decode 共置方案中的 GPU 硬件利用不足。
2. 提出动态时空编排机制，缓解 prefill 与 decode 之间的资源失配。
3. 引入高精度、低 profiling 开销的 SM 性能模型。
4. 设计 SLO 感知调度器，以适应工作负载变化。
5. 借助异步并发执行引擎，实现低开销运行时控制。

五 Bullet 在金融行业的应用场景分析

从金融业务视角来看，Bullet 并不是一个金融算法，而是一种大模型服务基础设施优化技术。它解决的是如何让企业在给定的 GPU 资源下，承载更多请求、降低响应时间并减少单位服务成本。这类能力在金融行业具有极强适配性。

5.1 智能客服与财富管理问答

银行、券商、保险公司的智能客服是大模型最基础的落地场景。该类业务每天面对大量用户请求，其中很多请求上下文很长，例如产品说明、合同条款、账户历史、风险测评记录等。这意味着 prefill 成本高，而用户又要求较快的首字响应与连续输出流畅。

传统分块预填充在高并发下易出现排队、卡顿问题。Bullet 能够更高效地协调长上下文输入与逐 token 输出，同等 GPU 资源下，可支撑更多在线用户，降低硬件扩容需求，在提升用户体验的同时压缩运维成本。

5.2 机构投研知识助手

证券研究所、资产管理公司、私募基金越来越多地建设内部“投研 Copilot”，需要模型综合研报、财报、公告、宏观数据回答问题。这类场景通

常输入很长，prefill 负担重。

Bullet 消除分块带来的 KV 缓存重复加载问题，大幅提升长文本推理效率。机构无需为投研系统单独配置大量 GPU，利用现有算力即可支撑多名分析师同时使用，降低机构数字化投入，助力投研效率提升。

5.3 合规审查与反洗钱文本分析

金融合规业务涉及制度文本、交易说明、客户材料、尽调文档等海量文本。大模型可以辅助识别异常表述、潜在违规、可疑交易说明等。此类应用往往存在两类混合请求形态：

- 长文档审阅：prefill 重
- 短问题追问：decode 互动多

Bullet 动态切换 SM 分配比例恰好适合这种异构请求混合场景。对于大型银行和持牌金融机构，这意味着可以在合规场景中部署更稳定的实时助手。

5.4 实时风控与运营监测

实时交易反欺诈、线上信贷智能审批属于金融核心高优先级业务，时延要求最为严苛，必须控制在毫秒级，且在交易高峰、营销大促、贷款申请集中时，请求量会快速波动，传统静态资源分配容易失效。

根据论文描述，Bullet 的调度器能够根据请求率波动实时调整 SM 预算，高峰期优先保障推理速度，低谷期提升硬件利用率。这既能应对突发请求洪峰，又能避免 GPU 长期闲置，完美适配实时风控、线上贷款审批等核心场景，保障金融业务安全稳定运行。

5.5 金融报告自动生成

券商晨报、基金周报、风险日报、审计摘要等报告生成任务，多在固定时段集中发生，属于高吞吐、时延容忍度较高的后台任务。传统架构批量任务会占用大量资源，影响前台服务。

Bullet 能可基于业务优先级划分资源，在统一 GPU 集群上更好承接这类混合流量，减少企业为不同任务分别建设专用资源池的需要。

六 技术落地的现实意义与挑战

6.1 现实意义

Bullet 最重要的商业意义在于，它不是简单提升某个模型精度，而是提升

服务层效率。这意味着企业在不更换模型的情况下，也可能得到明显收益：

- 降低单位推理成本
- 提升并发承载能力
- 改善用户响应体验
- 减少 GPU 扩容压力
- 提高私有化部署可行性

对于金融行业，基础设施效率提升往往能直接转化为 IT 预算节约和服务质量提升。

6.2 落地挑战

不过，这项技术在实际部署中仍可能面临若干挑战：

- 与现有推理框架、KV Cache 管理机制的兼容性问题
- 不同 GPU 架构下 SM 划分和调度策略的适配问题
- 多租户环境下的安全隔离与优先级控制问题
- 金融行业严格的审计、稳定性、容灾要求
- 对 SLO 定义是否足够贴近业务目标的问题

尤其在金融场景里，技术优化不仅要追求性能，还要符合高可用、可追踪、可治理的要求。

七 结论

综合论文内容可以看出，Bullet 关注的是大模型服务中如何突破 prefill 与 decode 的资源错配，缓解吞吐与时延之间的长期矛盾，从而提升 GPU 利用率。论文作者通过动态 SM 分配、并发执行引擎、SM-scaling roofline 模型与 SLO 感知调度器，构建了一个能够在保证延迟约束下提升吞吐的系统，并在真实负载中实现了平均 1.26 $\times$ 、最高 1.55 $\times$ 的吞吐收益。这一结果表明，面向大模型服务的系统级优化具有非常高的产业价值。

对金融行业而言，Bullet 的意义在于为大模型应用提供更高效率的算力底座。无论是智能客服、投研知识助手、合规审查、实时风控，还是报告生成，其本质都依赖稳定、低成本、低时延的大模型推理服务。因此，Bullet 代表了一条十分重要的发展路径，通过系统层调度创新，让大模型在企业真实场景中更可用、更经济、更可规模化部署。

从更广泛的产业趋势看，未来大模型竞争不仅取决于参数规模和能力上限，也越来越取决于是否能以合理成本稳定服务海量用户。在这一意义上，Bullet 这样的工作不仅是学术论文，更可能成为下一代企业级大模型基础设施的重要组成部分。

● 参考文献

Zeja Lin, Hongxin Xu, Guanyi Chen, Zhiguang Chen, Yutong Lu, and Xianwei Zhang.
2026. *Bullet: Boosting GPU Utilization for LLM Serving via Dynamic Spatial-Temporal*
Orchestration. In Proceedings of the 31st ACM International Conference on
Architectural Support for Programming Languages and Operating Systems
(ASPLOS '26). ACM, New York, NY, USA, 290–306.
<https://doi.org/10.1145/3779212.3790135>